



Universidade Federal de Pernambuco
Centro de Informática

Graduação em Engenharia da Computação

Análise comparativa de técnicas de seleção de protótipos

Dayvid Victor Rodrigues de Oliveira

Trabalho de Graduação

Recife
22 de novembro de 2011

Universidade Federal de Pernambuco
Centro de Informática

Dayvid Victor Rodrigues de Oliveira

Análise comparativa de técnicas de seleção de protótipos

Trabalho apresentado ao Programa de Graduação em Engenharia da Computação do Centro de Informática da Universidade Federal de Pernambuco como requisito parcial para obtenção do grau de Bacharel em Engenharia da Computação.

Orientador: *Prof. Dr. George Darmiton*

Recife
22 de novembro de 2011

*Eu dedico este trabalho a João Rodrigues de Silva, meu
avô.*

Agradecimentos

Agradeço a Deus.

What can I give back to God, for the blessings You pour out on me?

—BONO (Boston, 2001)

Resumo

RESUMO

Palavras-chave: PORTUGUES

Abstract

ABSTRACT

Keywords: INGLES

Sumário

1	Técnicas de Seleção de Protótipos	1
1.1	Motivação e Contextualização	1
1.1.1	Seleção de Protótipos	1
1.1.2	Bases Desbalanceadas	1
1.2	Objetivo	1
1.3	Estrutura do Trabalho	1
1.3.1	Sessões	1
1.3.2	Metodologia Utilizada	1
1.3.3	Bases de dados	1
2	Técnicas de Seleção de Protótipos	2
2.1	ENN	2
2.2	Tomek Links	3
2.3	CNN	3
2.4	LVQ	3
2.4.1	LVQ 1	3
2.4.2	LVQ 2.1	3
2.4.3	LVQ 3	3
2.5	SGP	3
2.6	SGP 2	3
2.7	CCNN	3

Lista de Figuras

Lista de Tabelas

Técnicas de Seleção de Protótipos

1.1 Motivação e Contextualização

Classificadores são (...)

*"I have a dream for the Web [in which computers] become capable of analyzing all the data on the Web, the content, links, and transactions between people and computers. A **Semantic Web** which should make this possible has yet to emerge, but when it does, the day-to-day mechanisms of trade, bureaucracy and our daily lives will be handled by machines talking to machines. The **intelligent agents** people have touted for ages will finally materialize."*Tim Berners-Lee

Tradução literal: *"Eu tenho um sonho para a Web [em que os computadores] tornam-se capazes de analisar todos os dados na Web, o conteúdo, links, e as transações entre pessoas e computadores. A **Web Semântica** que deve tornar isso possível ainda está para surgir; mas quando isso acontecer, os mecanismos dia-a-dia da burocracia do comércio e nossas vidas diárias serão tratados por máquinas falando com máquinas. Os **agentes inteligentes** que as pessoas têm falado por anos vão finalmente se concretizar."*Tim Berners-Lee

1.1.1 Seleção de Protótipos

1.1.2 Bases Desbalanceadas

1.2 Objetivo

1.3 Estrutura do Trabalho

1.3.1 Sessões

1.3.2 Metodologia Utilizada

1.3.3 Bases de dados

Técnicas de Seleção de Protótipos

Neste capítulo, serão mostradas as técnicas de seleção de protótipos abordadas neste trabalho. Cada uma das sessões abaixo abordará uma técnica, será mostrado o conceito da técnica, assim como o pseudo-código e as características de cada uma destas técnicas.

2.1 ENN

Edited Nearest Neighbor Rule[CPZ11] é uma técnica de seleção de protótipos puramente seletiva proposta por Wilson em 1976. De uma forma geral, esta técnica foi projetada para funcionar como um filtro de ruídos, ela elimina pontos na região de fronteira, região de alta susceptibilidade a erros, e com isso elimina ruídos.

Por atuar apenas na região de fronteira, esta técnica possui uma baixa capacidade de redução, deixando as instâncias que não se encontram na região de fronteira intactas, exceto pelos ruídos extremos.

Uma desvantagem desta técnica é que ela possui uma baixa capacidade de redução de elementos, visto que ela não elimina redundância.

Segue abaixo o algoritmo da execução do ENN e, logo após, alguns comentários sobre este algoritmo.

Algorithm 1 ENN

Require: *list*: uma lista

1. **for all** instância e_i da base de dados original **do**
 2. Aplique o KNN sobre e_i
 3. **if** e_i foi classificado erroneamente **then**
 4. salve e_i em *list*
 5. **end if**
 6. **end for**
 7. Remova da base de dados todos os elementos que estão em *list*
-

O valor de K pode variar de acordo com o tamanho da base de dados, porém, tipicamente, utiliza-se o valor de K=3. Tipicamente, O valor de K é inversamente proporcional a quantidade de instâncias que serão eliminadas, ou seja, para que o filtro elimine todos os possíveis ruídos, deve-se utilizar K=1.

As figuras, obtidas de [?], exemplificarão o funcionamento do ENN.

Nas figuras acima, caso o ENN fosse aplicado, todas as instâncias permaneceriam, exceto a assinalada com uma interrogação, pois esta se encontra em uma região de indecisão. Na

primeira figura, a instância, da classe *A*, está mais próxima de uma instância da classe *A*, assim, não seria removida caso o ENN fosse aplicado com $K=1$. Já na segunda figura, caso o ENN fosse aplicado com $K=3$, esta instância seria removida, pois a mesma foi classificada erroneamente pelos seus vizinhos.

Uma vantagem do ENN é que ele independe da ordem que a base de dados foi apresentada, ou seja, o ENN aplicado a uma base de dados, com o mesmo valor de K , sempre terá o mesmo resultado.

Os problemas do ENN é que esta técnica não remove os elementos que causam redundância. Nas figuras mostradas anteriormente, vemos que as instâncias da classe *B* localizadas mais a direita poderiam ser eliminadas sem comprometer o resultado. Existem outras técnicas que resolvem este problema, elas serão vistas em próximas sessões.

2.2 Tomek Links

2.3 CNN

2.4 LVQ

2.4.1 LVQ 1

2.4.2 LVQ 2.1

2.4.3 LVQ 3

2.5 SGP

2.6 SGP 2

2.7 CCNN

Referências Bibliográficas

- [CPZ11] Ruiqin Chang, Zheng Pei, and Chao Zhang. A modified editing k-nearest neighbor rule. *JCP*, 6(7):1493–1500, 2011.
- [dSPC08] Cristiano de Santana Pereira and George D. C. Cavalcanti. Prototype selection: Combining self-generating prototypes and gaussian mixtures for pattern classification. In *IJCNN*, pages 3505–3510. IEEE, 2008.
- [EJJ04] Andrew Estabrooks, Taeho Jo, and Nathalie Japkowicz. A multiple resampling method for learning from imbalanced data sets. *Computational Intelligence*, 20(1):18–36, 2004.
- [FHA07] Hatem A. Fayed, Sherif Hashem, and Amir F. Atiya. Self-generating prototypes for pattern classification. *Pattern Recognition*, 40(5):1498–1509, 2007.
- [Har68] P. E. Hart. The condensed nearest neighbor rule. *IEEE Transactions on Information Theory*, 14:515–516, 1968.
- [HKN07] Jason Van Hulse, Taghi M. Khoshgoftaar, and Amri Napolitano. Experimental perspectives on learning from imbalanced data. In Zoubin Ghahramani, editor, *ICML*, volume 227 of *ACM International Conference Proceeding Series*, pages 935–942. ACM, 2007.
- [Koh86] Teuvo Kohonen. Learning vector quantization for pattern recognition. Report TKK-F-A601, Laboratory of Computer and Information Science, Department of Technical Physics, Helsinki University of Technology, Helsinki, Finland, 1986.
- [Koh88] Teuvo Kohonen. Learning vector quantization. *Neural Networks*, 1, Supplement 1:3–16, 1988.
- [PI69] E. A. Patrick and F. P. Fischer II. A generalization of the k-nearest neighbor rule. In *IJCAI*, pages 63–64, 1969.
- [Sav] Sergei Savchenko. <http://cgm.cs.mcgill.ca/>.
- [TC67] P.E. Hart T.M. Cover. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, IT-13:21 – 27, 1967.
- [Tom76] I. Tomek. Two Modifications of CNN. *IEEE Transactions on Systems, Man, and Cybernetics*, 7(2):679–772, 1976.

- [WP01] G. Weiss and F. Provost. The effect of class distribution on classifier learning, 2001.